Características do R

- Não foi feito para manipulação de dados em larga escala.
- Forma mais fácil e direta de acessar os dados é convertê-los para texto e importar.
- Salva a sessão em um arquivo .RDATA, que armazena todos os objetos R, possibilitando que um projeto seja retomado posteriormente ou intercambiado com colaboradores.
- Acessa bancos de dados e planilhas Microsoft Excel via ODBC e outros bancos de dados por servidor SQL, ampliando a capacidade de trabalhar com dados em larga escala.
- A partir da versão 2.1.1 possui um editor de script, que facilita a execução de comandos diretamente de dentro do R.
- Possui pacotes com funções específicas que podem ser instalados pela Internet, através do próprio programa.
- Conta com inúmeros colaboradores no mundo inteiro que criam, testam e corrigem as funções que podem ser usadas por qualquer pessoa.
- Gera gráficos em diferentes formatos para as mais diversas utilizações.

Importação de dados

Salvando arquivos separados por vírgula (CSV) no Microsoft Excel

Para importar dados a partir de uma planilha do Microsoft Excel, é necessário antes salvar essa planilha no formato .CSV (valores separados por vírgula). Para salvá-la nesse formato, clique em **Arquivo** do menu, em seguida **Salvar como...** . Na parte inferior da caixa de diálogo, clique sobre as opções de **Salvar como tipo** e selecione **CSV (separado por vírgulas)**. Agora basta escolher a pasta de destino e clicar no botão **Salvar**. Surgirão algumas mensagens indicando a incompatibilidade de alguns recursos do Microsoft Excel com esse formato, mas como o que nos interessa são apenas os dados, clique em **OK** e em seguida em **SIM**.

Lendo arquivos do tipo CSV (separado por vírgulas)

Podemos usar o comando **read.csv** para armazenar os dados desse arquivo em um objeto do R chamado ***dados***:

sintaxe:

```
dados <- read.csv("caminho_e_nome_do_arquivo.csv", opções)
```

opções:

sep: caractere utilizado para separação dos campos e valores. Normalmente é utilizado o ponto e vírgula (;)

dec: caractere utilizado para separar as casas decimais. Normalmente ponto (.) ou vírgula (,).

header: TRUE, assume que a primeira linha da tabela contém rótulos das variáveis. FALSE, assume que os dados se iniciam na primeira linha.

exemplo:

Importa os dados provenientes do arquivo caries.csv, presente no drive C, pasta Analises descritivas, subpasta odonto, com vírgula como sinal decimal, ponto e vírgula como separador de campos e valores e armazena no objeto de nome caries:

```
> caries <- read.csv("C:/Analises descritivas/odonto/caries.csv", sep=";", dec=",", header=TRUE)
```

Visualiza os dados obtidos e armazenados no objeto caries:

```
> caries
  X1 X10
1  2  12
2  3  15
3  4  18
4  5  22
```

Observação: Pode-se optar por utilizar as **barras normais** como indicadoras do caminho do arquivo, ou **barras invertidas duplas**.
Ex: C:\\Analises descritivas\\odonto\\caries.csv tem o mesmo efeito de C:/Analises descritivas/odonto/caries.csv.

Arquivos em banco de dados (ODBC)

É possível acessarmos bancos de dados previamente configurados através do ODBC (Open DataBase Connectivity). A grande vantagem é que podemos acessar bancos de dados extremamente grandes sem prejudicar o desempenho do processamento no R, pois os dados não serão armazenados na memória RAM, mas acessados diretamente do disco rígido sempre que necessário.

Funções Estatísticas

Tabelas

sintaxe:

table(*dados*)

exemplo:

Dados utilizados da tabela 2.1 de Bussab e Morettin (2003).

```
table(dados$origem)
 Capital Interior   Outros
      11       12       13

table(dados$origem,dados$estciv)
           Casado Solteiro
  Capital       7        4
  Interior      8        4
  Outros        5        8

table(dados$origem,dados$estciv,dados$educa)
, ,  = Ensino Fundamental
           Casado Solteiro
  Capital       2        2
  Interior      1        2
  Outros        2        3

, ,  = Ensino Médio
           Casado Solteiro
  Capital       4        1
  Interior      6        1
  Outros        2        4

, ,  = Superior
           Casado Solteiro
  Capital       1        1
  Interior      1        1
  Outros        1        1
```

Tabela de proporções

Mostra os dados em formato de tabela usando proporções:

sintaxe:

prop.table(*tabela*)

Exemplo:

```
prop.table(table(dados$Educacao))

Ensino Fundamental       Ensino Médio           Superior
         0.3333333          0.5000000          0.1666667
```

Resumo

Resume a variável quantitativa em: mínimo, máximo, média, mediana, 1° quartil, 3° quartil e dados não preenchidos. Caso a variável seja qualitativa, é informado o número de observações para cada nível.

sintaxe:

summary(*variável*)

Exemplo:

Resumo da variável salário

```
summary(dados$Salario)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  4.000   7.553  10.160  11.120  14.060  23.300
```

Resumo da variável salário apenas para casados

```
summary(dados$salario[dados$estciv=="Casado"])
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  4.560   8.743  11.930  12.120  15.030  23.300
```

Resumo da variável salário apenas para solteiros

```
summary(dados$salario[dados$estciv=="Solteiro"])
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  4.000   7.257   9.045   9.871  11.690  18.750
```

Resumo da variável qualitativa origem

```
summary(dados$Origem)
 Capital Interior   Outros
      11       12       13
```

Observação: Caso a variável desejada seja **qualitativa numérica**, é possível que o R interprete-a como sendo uma variável **quantitativa**. Para evitar que isso aconteça, utilize a função **as.factor()**.
Ex: summary(as.factor(dados$sexo))

Média

sintaxe:

mean(*variável*)

Opções:

na.rm: TRUE, calcula a média considerando apenas os dados existentes, ignora os dados faltantes.
FALSE, calcula a média apenas se todos os valores estiverem preenchidos, caso contrário retorna NA.

Exemplo:

```
mean(dados$Filhos)
[1] NA

mean(dados$Filhos, na.rm=TRUE)
[1] 1.65
```

Variância

sintaxe:

var(*variável*)

Opções:

na.rm: TRUE, calcula a variância considerando apenas os dados existentes, ignora os dados faltantes.
FALSE, calcula a variância apenas se todos os valores estiverem preenchidos, caso contrário retorna NA.

Exemplo:

```
var(dados$Filhos)
Erro em var(dados$Filhos) : observações faltantes em cov/cor

var(dados$Filhos, na.rm=TRUE)
[1] 1.607895
```

Desvio Padrão

sintaxe:

sd(*variável*)

Opções:

na.rm: TRUE, calcula o desvio padrão considerando apenas os dados existentes, ignora os dados faltantes.
FALSE, calcula o desvio padrão apenas se todos os valores estiverem preenchidos, caso contrário retorna NA.

Exemplo:

```
sd(dados$Filhos)
Erro em var(dados$Filhos) : observações faltantes em cov/cor

sd(dados$Filhos, na.rm=TRUE)
[1] 1.268028
```

Mediana

Calcula a mediana do conjunto de dados.

median(*variável*)

Opções:

na.rm = TRUE calcula a mediana considerando apenas os dados existentes, ignora os dados faltantes.
FALSE calcula a mediana apenas se todos os valores estiverem preenchidos, caso contrário retorna NA.

Exemplo:

```
median(dados$Filhos)
[1] NA

median(dados$Filhos, na.rm=TRUE)
[1] 2
```

Aplica funções

Aplica a função desejada na variável escolhida segundo cada nível de um determinado fator.

sintaxe:

tapply(*variável, fator, função*)

Exemplo:

```
tapply(dados$Salario,dados$Estado,summary)
$Casado
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  4.560   8.743  11.930  12.120  15.030  23.300

$Solteiro
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  4.000   7.257   9.045   9.871  11.690  18.750

tapply(dados$Salario,dados$Estado,var)
  Casado Solteiro
24.12800 15.53465
```

Divisão de dados

Divide os dados em faixas determinadas.

sintaxe:

cut(*variável, faixas, rótulos, opções*)

Opções:

right: TRUE faz com que o intervalo seja fechado na direita e aberto na esquerda.
FALSE faz com que o intervalo seja aberto na direita e fechado na esquerda.

Exemplo:

```
cut(dados$Anos, breaks=c(20,30,40,50), labels=c("A","B","C"), right=FALSE)
 [1] A B B A C A C C B A B A B C B B B B A B B B C A B B C A C B B B C B C C
Levels: A B C

table(cut(dados$Anos,    breaks=c(20,30,40,50),    labels=c("20|-30","30|-40","40|-50"),
right=F))

20|-30 30|-40 40|-50
     8     18     10


table(cut(dados$Salario,     breaks=c(4,8,12,16,20,24),     labels=c("4|-8","8|-12","12|-
16","16|-20","20|-24"), right=F))

  4|-8  8|-12 12|-16 16|-20 20|-24
    10     12      8      5      1
```

Observação: É possível a utilização da função cut() dentro da função table() diretamente. O resultado será uma tabela com a freqüência de cada intervalo determinado pela função cut().

lm

Cria um modelo linear que pode ser utilizando para regressão linear, análise de variância entre outros.

sintaxe:

lm(formula, dados, opções)

Parâmetros

formula: Especifica a relação entre a variável resposta e a variável explicativa. Ver exemplos.

dados: Objeto do tipo data.frame que contém os dados.

Opções

weights: vetor opcional dos pesos a serem utilizados no processo de ajuste do modelo linear.

Exemplos

Cria um modelo linear baseado na tabela 15.1 de Bussab e Morettin (2003), onde o objeto dados contém a tabela.

```
lm(Reação ~ Idade, dados)

Call:
lm(formula = Reação ~ Idade, data = dados)

Coefficients:
(Intercept)        Idade
       80.5          0.9
```

A função lm() nos retorna a estimativa dos parâmetros do modelo linear da forma: $E(Y \mid x) = \mu(x) = \alpha + \beta \cdot x$, onde α corresponde ao valor esperado para a variável dependente quando a variável explicativa assume o valor zero (também chamado de Intercepto ou coeficiente linear da reta) e β corresponde à variação média da variável dependente por unidade de variação da variável explicativa (ou coeficiente angular da reta). No exemplo acima, o modelo seria representado pela equação: $\hat{E}(Y \mid x) = \hat{\mu}(x) = 80{,}5 + 0{,}9 \cdot x$.

Caso necessário, pode-se remover o intercepto do modelo alterando a fórmula da seguinte maneira:

```
lm(Reação ~ Idade - 1, dados)

Call:
lm(formula = Reação ~ Idade - 1, data = dados)

Coefficients:
Idade
3.442
```

Testes para a média populacional e para a comparação de duas médias

t.test()
Realiza o teste t-Student para uma ou duas amostras.

sintaxe:
t.test(*amostra1, amostra2, opções*)

Parâmetros
amostra1: Vetor contendo a amostra da qual se quer testar a média populacional, ou comparar a média populacional com a média populacional da amostra 2.
amostra2: Vetor contendo a amostra 2 para comparação da média populacional com a média populacional da amostra 1.

Opções
alternative: string indicando a hipótese alternativa desejada.
Valores possíveis: "two-sided", "less" ou "greater".

mu: valor indicando o verdadeiro valor da média populacional para o caso de uma amostra, ou a diferença entre as médias para o caso de duas amostras.

paired: TRUE - realiza o teste t pareado.
FALSE - realiza o teste t não pareado.

var.equal:TRUE - indica que a variância populacional é a igual nas duas amostras.
FALSE - indica que a variância populacional de cada amostra é diferente.

conf.level: coeficiente de confiança do intervalo.

Exemplo:
Teste t para média populacional
```
amostra1 = c(14.9,13.4,14.5,13.5,15.0,13.9,14.9,16.4,14.6,15.4)
t.test(amostra1,mu=15)
```

```
        One Sample t-test
data:  amostra1
t = -1.2252, df = 9, p-value = 0.2516
alternative hypothesis: true mean is not equal to 15
95 percent confidence interval:
 14.00375 15.29625
sample estimates:
mean of x
    14.65
```

Teste t para comparação de duas médias com variâncias iguais
```
amostra1 = c(16.6,13.4,14.6,15.1,12.9,15.2,14.0,16.6,15.4,13.0)
amostra2 = c(15.8,17.9,18.2,20.2,18.1,17.8,18.3,18.6,17.0,18.4)
t.test(amostra1, amostra2, var.equal = TRUE)
```

```
      Two Sample t-test
data:  amostra1 and amostra2
t = -6.0257, df = 18, p-value = 1.069e-05
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -4.518003 -2.181997
sample estimates:
mean of x mean of y
    14.68     18.03
```

Teste t pareado

```
antes = c(16.6,13.4,14.6,15.1,12.9,15.2,14.0,16.6,15.4,13.0)
depois = c(15.8,17.9,18.2,20.2,18.1,17.8,18.3,18.6,17.0,18.4)
t.test(antes,depois,paired=TRUE)

        Paired t-test
data:  antes and depois
t = -5.3231, df = 9, p-value = 0.000479
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -4.773642 -1.926358
sample estimates:
mean of the differences
                  -3.35
```

Testes para uma proporção populacional e para comparação de duas proporções

prop.test()
Realiza o teste de proporções para uma ou duas amostras.

sintaxe:
prop.test(*x, n, p, opções*)

Parâmetros
x: Vetor contendo o número de sucessos em cada amostra.
n: Vetor contendo o número de realizações de cada amostra.
p: Vetor contendo as probabilidades de sucesso de cada amostra.

Opções
alternative: string indicando a hipótese alternativa desejada.
Valores possíveis: "two-sided", "less" ou "greater".

conf.level: coeficiente de confiança do intervalo.

correct: TRUE – indica que a correção de continuidade de Yates será aplicada.
FALSE – indica que a correção de continuidade não será aplicada.

Exemplo:
Teste para uma proporção populacional

```
prop.test(104,200,0.6,correct=F)

        1-sample proportions test without continuity correction

data:  104 out of 200, null probability 0.6
X-squared = 5.3333, df = 1, p-value = 0.02092
alternative hypothesis: true p is not equal to 0.6
95 percent confidence interval:
 0.4510379 0.5882083
sample estimates:
   p
0.52
```

Teste para comparação de duas proporções

```
prop.test(c(104,50),c(200,95),correct=F)

        2-sample test for equality of proportions without continuity
        correction

data:  c(104, 50) out of c(200, 95)
X-squared = 0.0103, df = 1, p-value = 0.9192
alternative hypothesis: two.sided
95 percent confidence interval:
 -0.1282799  0.1156483
sample estimates:
   prop 1    prop 2
0.5200000 0.5263158
```

fisher.test()

Realiza o teste exato de independência de linhas e colunas em uma tabela de contingência com as marginais fixas.

Sintaxe:

fisher.test(*x, opções*)

Parâmetros

x: Matriz (tabela) contendo a frequência de observações em cada casela.

Opções

alternative: string indicando a hipótese alternativa desejada.
Valores possíveis: "two-sided", "less" ou "greater".

conf.int: TRUE: calcula o intervalo de confiança para a razão de chances em tabelas de dimensão 2x2.

conf.level: coeficiente de confiança do intervalo.

Exemplo:

Teste de independência do exemplo: Satisfação no trabalho, Agresti(2002, p.57)

Receita	Satisfação			
	Muito Insatisfeito	Pouco Insatisfeito	Moderadamente Satisfeito	Muito Satisfeito
< 15 mil	1	3	10	6
15-25 mil	2	3	10	7
25-40 mil	1	6	14	12
> 40 mil	0	1	9	11

```
Trabalho = matrix(c(1,2,1,0, 3,3,6,1, 10,10,14,9, 6,7,12,11), 4, 4,
   dimnames = list(Receita=c("< 15mil", "15-25mil", "25-40mil", "> 40mil"),
   Satisfação=c("M.Insatisfeito", "P.Insatisfeito", "Mod.Satisfeito", "M.Satisfeito")))


fisher.test(Trabalho)

        Fisher's Exact Test for Count Data

data:  Trabalho
p-value = 0.7827
alternative hypothesis: two.sided
```

Testes para Normalidade

Estes pacotes contém diversos testes que verificam se os dados amostrais contém evidências de serem oriundos de uma população com distribuição Normal.

Pacote: base

Este pacote já está instalado.

shapiro.test()

Realiza o teste de Shapiro-Wilk para normalidade.

sintaxe:

shapiro.test(*amostra*)

Parâmetros

amostra: Vetor contendo a amostra da qual se quer testar normalidade.
Deve conter uma amostra de tamanho entre 3 e 5000.
São permitidos *missing values*.

Exemplo:

```
shapiro.test(rnorm(10, mean=10, sd=4))
        Shapiro-Wilk normality test

data:  rnorm(10, mean = 10, sd = 4)
W = 0.9779, p-value = 0.9532
```

Pacote opcional: nortest

Este pacote precisa ser instalado. Ver guia primeiros contatos com R.

ad.test()

Realiza o teste de Anderson-Darling para normalidade.

sintaxe:

ad.test(*amostra*)

Parâmetros

amostra: Vetor contendo a amostra da qual se quer testar normalidade.
Deve conter uma amostra de tamanho maior ou igual a 7.
São permitidos *missing values*.

Exemplo:

```
ad.test(rnorm(10, mean=10, sd=4))
        Anderson-Darling normality test

data:  rnorm(10, mean = 10, sd = 4)
A = 0.2772, p-value = 0.5707
```

cvm.test()

Realiza o teste de Cramer-von Mises para normalidade.

sintaxe:

cvm.test(*amostra*)

Parâmetros

amostra: Vetor contendo a amostra da qual se quer testar normalidade.
Deve conter uma amostra de tamanho maior ou igual a 7.
São permitidos missing values.

Exemplo:

```
cvm.test(rnorm(10, mean=10, sd=4))
        Cramer-von Mises normality test

data:  rnorm(10, mean = 10, sd = 4)
W = 0.0497, p-value = 0.4792
```

lillie.test()

Realiza o teste de Lilliefors (Kolmogorov-Smirnov) para normalidade.

sintaxe:

lillie.test(*amostra*)

Parâmetros

amostra: Vetor contendo a amostra da qual se quer testar normalidade.
Deve conter uma amostra de tamanho maior ou igual a 4.
São permitidos missing values.

Exemplo:

```
lillie.test(rnorm(10, mean=10, sd=4))
        Lilliefors (Kolmogorov-Smirnov) normality test

data:  rnorm(10, mean = 10, sd = 4)
D = 0.2169, p-value = 0.2010
```

pearson.test()

Realiza o teste Qui-quadrado de Pearson para normalidade.

sintaxe:

pearson.test(*amostra*)

Parâmetros

amostra: Vetor contendo a amostra da qual se quer testar normalidade.
São permitidos missing values.

Opções

n.classes: Número de classes.
São permitidos missing values.

adjust: **TRUE**: o valor p é calculado de uma distribuição Qui-quadrado com o número de graus de liberdade igual ao número de classes – 3.
FALSE: o valor p é calculado de uma distribuição Qui-quadrado com o número de graus de liberdade igual ao número de classes – 1.

Exemplo:

```
pearson.test(rnorm(10, mean=10, sd=4))
        Pearson chi-square normality test

data:  rnorm(10, mean = 10, sd = 4)
P = 2, p-value = 0.5724
```

sf.test()

Realiza o teste de Shapiro-Francia para normalidade.

sintaxe:

sf.test(*amostra*)

Parâmetros

amostra: Vetor contendo a amostra da qual se quer testar normalidade.
Deve conter uma amostra de tamanho entre 5 e 5000.
São permitidos missing values.

Exemplo:

```
sf.test(rnorm(10, mean=10, sd=4))
        Shapiro-Francia normality test

data:  rnorm(10, mean = 10, sd = 4)
W = 0.935, p-value = 0.4419
```

Testes para comparação de variâncias

Pacote: stats

Este pacote já está instalado.

bartlett.test()

Realiza o teste de Bartlett com a hipótese nula de que as variâncias dos grupos são iguais.

sintaxe:

bartlett.test(*formula, dados*)

Parâmetros

formula: Relação entre a variável dependente e o fator. Ex: "Vendas ~ Mês".
dados: Conjunto de dados onde será aplicada a formula.

Exemplo: Queremos comparar a variabilidade das vendas entre os meses

Loja	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
A	10	14	16	19	12	15	11	10	12	13	18	23
B	12	13	13	14	13	11	16	09	11	11	16	25
C	15	17	12	16	10	16	12	12	08	14	21	24

```
Vendas = c(10,12,15,14,13,17,16,13,12,19,14,16,12,
      13,10,15,11,16,11,16,12,10,9,12,12,
      11,8,13,11,14,18,16,21,23,25,24)
Mes = c("Jan","Jan","Jan","Fev","Fev","Fev","Mar","Mar","Mar","Abr","Abr","Abr",
      "Mai","Mai","Mai","Jun","Jun","Jun","Jul","Jul","Jul","Ago","Ago","Ago",
      "Set","Set","Set","Out","Out","Out","Nov","Nov","Nov","Dez","Dez","Dez")
dados = data.frame(Vendas=Vendas, Mes=Mes)

bartlett.test(Vendas ~ Mes, data=dados)

        Bartlett test of homogeneity of variances

data:  Vendas by Mes
Bartlett's K-squared = 2.844, df = 11, p-value = 0.9926
```

Observação: Também é possível especificar os grupos da seguinte forma: bartlett.test(list(*GRUPO1, GRUPO2*)), onde GRUPO1 e GRUPO2 são vetores contendo os valores das observações de cada amostra.

Exemplo:

	Jogo 1	Jogo 2	Jogo 3	Jogo 4	Jogo 5	Jogo 6
Time A	30	25	32	22	19	26
Time B	18	24	31	28	29	30

```
TimeA = c(30,25,32,22,19,26)
TimeB = c(18,24,31,28,29,30)

bartlett.test(list(TimeA, TimeB))

  Bartlett test of homogeneity of variances

data:  list(TimeA, TimeB)
Bartlett's K-squared = 3e-04, df = 1, p-value = 0.9856
```

Pacote: car

Este pacote precisa ser instalado.

levene.test()

Realiza o teste de Bartlett com a hipótese nula de que as variâncias dos grupos são iguais.

sintaxe:

bartlett.test(*formula, dados*)

Parâmetros

formula: Relação entre a variável dependente e o fator. Ex: "Vendas ~ Mês".
dados: Conjunto de dados onde será aplicada a formula.

Exemplo: Utilizando o mesmo exemplo visto no teste de Bartlett:

Loja	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
A	10	14	16	19	12	15	11	10	12	13	18	23
B	12	13	13	14	13	11	16	09	11	11	16	25
C	15	17	12	16	10	16	12	12	08	14	21	24

```
levene.test(dados$Vendas, dados$Mes)

Levene's Test for Homogeneity of Variance
      Df F value Pr(>F)
group 11  0.1678 0.9981
      24
```

Funções Matemáticas

Combinatória

Calcula o número de combinações de **n** elementos em grupos de tamanho **k**.

sintaxe:

```
choose(n,k)
```

exemplo:

```
choose(0,0)
[1] 1

choose(8,5)
[1] 56
```

Fatorial

Calcula o fatorial de **x**.

sintaxe:

```
factorial(x)
```

exemplo:

```
factorial(0)
[1] 1

factorial(5)
[1] 120
```

Raiz Quadrada

Calcula a raiz quadrada de **x**.

sintaxe:

```
sqrt(x)
```

exemplo:

```
sqrt(0)
[1] 0

sqrt(81)
[1] 9
```

Gráficos

Os gráficos nos permitem analisar uma grande quantidade de informações de forma rápida, sem que seja necessário olhar tabelas e medidas de resumo. O R possui uma enorme capacidade para gerar diversos tipos de gráficos de alta qualidade totalmente configuráveis, desde cores e tipos de linhas, até legendas e textos adicionais.

A grande maioria das funções gráficas faz uso de opções comuns, ou seja, é extremamente fácil personalizar qualquer tipo de gráfico pois muitas das opções são iguais. As opções comuns a todos os gráficos serão abordadas aqui, e em cada seção seguinte as opções específicas àquele determinado tipo de gráfico serão apresentadas.

Opções:

```
xlim: (inicio,fim) dupla contendo os limites do eixo X.
ylim: (inicio,fim) dupla contendo os limites do eixo Y.
xlab: rótulo para o eixo X.
ylab: rótulo para o eixo Y.
main: título principal do gráfico.
col:  cor de preenchimento do gráfico, podendo ser um vetor. A lista das cores
      disponíveis pode ser obtida através do comando colors().
```

locator

Permite localizar uma coordenada clicando com o mouse no gráfico. Se não for definida a opção ***type***, retorna apenas as coordenadas do ponto clicado. Útil para inserir textos e outros elementos em gráficos já prontos.

sintaxe:

```
locator()
```

Opções

```
n:    Número máximo de pontos a localizar.
type: p: cria pontos no gráfico com as coordenadas indicadas pelo mouse.
      l:  cria linhas no gráfico com as coordenadas indicadas pelo mouse.
```

text

Insere um texto nas coordenadas definidas.

sintaxe:

```
text(x, y, labels, cex, col)
```

Opções

```
x:    Posição relativa a abscissa (eixo X).
y:    Posição relativa a ordenada (eixo Y).
labels: Texto (ou vetor com textos) a ser inserido nas coordenadas definidas por
        x e y.
cex:  Proporção relativa ao tamanho dos caracteres do texto (padrão: 1).
col:  Cor do texto a ser inserido (padrão: preto).
```

Gráfico de barras

Gráfico de freqüências para variáveis qualitativas.

sintaxe:

barplot(*dados*,*opções*)

opções:

space: espaço deixado antes de cada barra
width: vetor contendo a largura relativa de cada barra com relação as demais. Valores iguais para todas as barras não terão efeito, pois a relação entre elas será 1.

exemplo:

```
barplot(table(dados$estciv), col=c("blue","red"),
      ylim=c(0,25),
      space=.8, width=c(.2,.2),
      main="Número de filhos por estado civil",
      xlab="Estado Civil", ylab="Número de Filhos")

text(locator(n=2),c("56%","44%"))
```

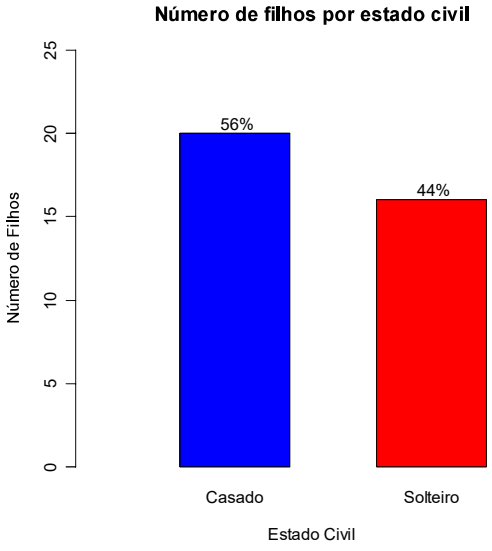

Observação:

- Caso não seja especificada a opção **xlim**, os valores da opção **width** não serão interpretados como **valores absolutos**, mas como **valores relativos** as demais barras.
  Ex: barplot(table(dados$estciv), width(0.2,0.2)) tem o mesmo efeito que **barplot**(table(dados$estciv), width(2,2))

- Após o comando text(locator(n=2), c("56%","44%")), são necessários dois cliques em pontos do gráfico de barras onde serão inseridos os textos com os percentuais relativos a cada barra.

Histograma

Gráfico de distribuição de freqüências para variáveis quantitativas.

sintaxe:

hist(*dados*, *opções*)

opções:

prob: T plota a densidade.
F plota a freqüência absoluta.
breaks: vetor contendo os pontos de definição das larguras das barra do histograma.

exemplo:

```
hist(cdnotas$Notas, main="Histograma da variável Notas",
      prob=T, xlab="Notas", ylab="Densidade",
      col=c("pink"), ylim=c(0,0.3), col.main="darkgray")
```

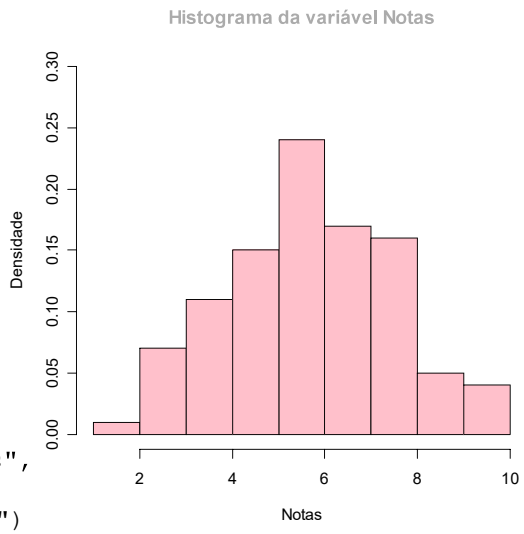

Boxplot

sintaxe:

boxplot(*dados*, *opções*)

opções:

outline: T plota os outliers.
F não plota os outliers.

exemplo:

```
boxplot(dados$salario, main="Boxplot de Salários",
      ylab="Salários", col=("green"))
```

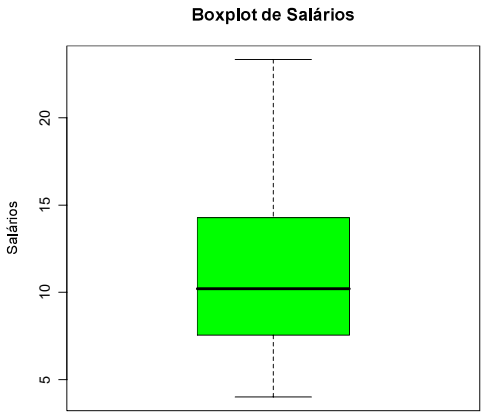


```
boxplot(dados$salario ~ dados$educa,
      main="Boxplot de Salários por grau de Instrução",
      xlab="Grau de Instrução", ylab="Salários",
      col=c("yellow","orange","red"))
```

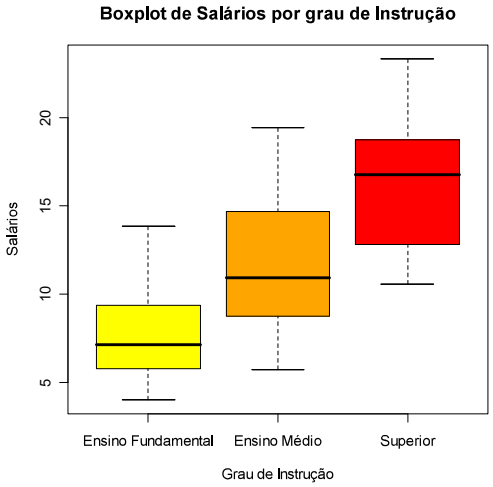

Gráfico de Pizza

sintaxe:

pie(*dados*, *opções*)

opções:

labels: vetor contendo os rótulos de cada fatia.
radius: raio da circunferência da pizza. (padrão=1)
col: vetor contendo as cores das fatias.

exemplo:

```
pie(table(dados$educa),
      main="Gráfico de setores: Grau de Instrução")
```

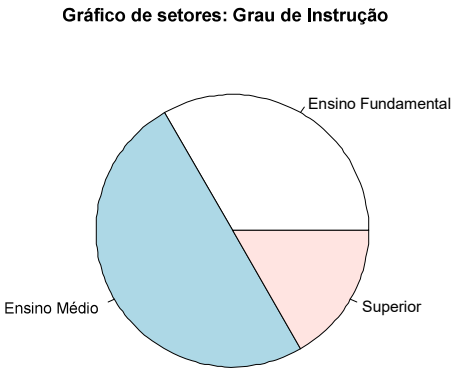

Para incluir as porcentagens dentro de cada fatia, execute as linhas abaixo clicando na fatia branca, azul e rosa, nesta sequência.

```
text(locator(n=1),
      paste(round(prop.table(table(dados$educa))[1],
      digits=2)*100,"%"))
text(locator(n=1),
      paste(round(prop.table(table(dados$educa))[2],
      digits=2)*100,"%"))
text(locator(n=1),
      paste(round(prop.table(table(dados$educa))[3],
      digits=2)*100,"%"))
```

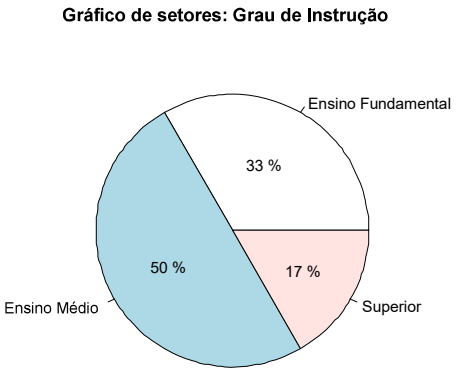

Gráfico de Dispersão

Plota dados2 em função de dados1.

sintaxe:

plot(*dados1*, *dados2*, *opções*)

opções:

pch: Escolhe o tipo de caractere.
lwd: Espessura do caractere a ser plotado

exemplo:

```
plot(dados$filhos, dados$salario, pch=1, lwd=2,
      main="Gráfico de dispersão: Salário x Idade",
      xlab="Idade (anos)", ylab="Salários")
```

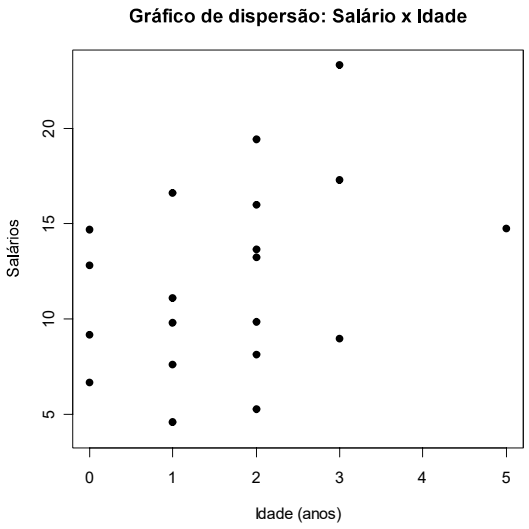

Probabilidade

Função Densidade (ou Probabilidade)

Calcula o valor da densidade, no caso de distribuições contínuas, ou a probabilidade P(X=x), no caso de distribuições discretas, para cada elemento do vetor x. No R o nome dessa função é iniciado pela letra **d** mais o nome da distribuição (ex: dbinom, dpois etc.).

Função Distribuição

Calcula a distribuição acumulada: $P(X \leq x)$. O nome da função é iniciado pela letra **p** mais o nome da distribuição (ex: pnorm, pexp etc.).

Função Probabilidade

Calcula o valor de x correspondente a probabilidade p acumulada. É o inverso da função Distribuição. O nome da função é iniciado pela letra **q** mais o nome da distribuição (ex: qbeta, qcauchy etc.).

Gerador aleatório

Gera números aleatórios baseados na distribuição definida. O nome da função é iniciado pela letra r mais o nome da distribuição (ex: rnorm, rbinom etc.).

Distribuição	Sintaxe	Opções
Binomial	dbinom(x, n, p, opções) pbinom(q, n, p, opções) qbinom(prob, n, p, opções) rbinom(obs, n, p)	**x:** vetor contendo o número total de sucessos em n ensaios de Bernoulli. **p:** probabilidade de sucesso. **q:** vetor contendo os quantis em n ensaios de Bernoulli. **prob:** vetor contendo as probabilidades em n ensaios de Bernoulli. **obs:** número de observações. **n:** número de ensaios de Bernoulli.
Poisson	dpois(x, lambda, opções) ppois(q, lambda, opções) qpois(prob, lambda, opções) rpois(obs, lambda)	**x:** vetor contendo o número de ocorrências. **lambda:** número médio de eventos ocorrendo no intervalo considerado. **q:** vetor contendo os quantis. **prob:** vetor contendo as probabilidades. **obs:** número de observações.
Geométrica	dgeom(x, prob, opções) pgeom(q, prob, opções) qgeom(p, prob, opções) rgeom(n, prob)	**x:** vetor contendo o número de falhas ocorridas em uma sequência de Bernoulli antes do sucesso. **prob:** probabilidade de sucesso em cada tentativa. **q:** vetor contendo os quantis **p:** vetor contendo as probabilidades **n:** número de observações.

Fernando Itano
Instituto de Matemática e Estatistica
Universidade de São Paulo
Soane Mota dos Santos

Hipergeométrica	dhyper(x, m, n, k, opções) phyper(q, m, n, k, opções) qhyper(p, m, n, k, opções) rhyper(nn, m, n, k)	**x**: vetor contendo o número de elementos com a característica A extraídos sem reposição de uma urna que contém elementos com características A e B. **m**: número de elementos com a característica A. **n**: número de elementos com a característica B. **k**: número de elementos extraídos da urna. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **nn**: número de observações.

Uniforme	dunif(x, min=0, max=1, opções) punif(q, min=0, max=1, opções) qunif(p, min=0, max=1, opções) runif(n, min=0, max=1)	**x**: vetor contendo os quantis. **min**: limite inferior da distribuição. **max**: limite superior da distribuição. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **n**: número de observações.

Exponencial E(X)=1/rate Var(X)=1/rate^2	dexp(x, rate=1, opções) pexp(q, rate=1, opções) qexp(p, rate=1, opções) rexp(n, rate = 1)	**x**: vetor contendo os quantis. **rate**: parâmetro da distribuição. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **n**: número de observações.

Normal	dnorm(x, mean=0, sd=1, opções) pnorm(q, mean=0, sd=1, opções) qnorm(p, mean=0, sd=1, opções) rnorm(n, mean=0, sd=1)	**x**: vetor contendo os quantis. **mean**: média da distribuição. **sd**: desvio padrão da distribuição. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **n**: número de observações.

Gama E(X)=shape/rate Var(X) = shape/rate^2	dgamma(x, shape, rate = 1, opções) pgamma(q, shape, rate = 1, opções) qgamma(p, shape, rate = 1, opções) rgamma(n, shape, rate = 1)	**x**: vetor contendo os quantis. **shape**: parâmetro da distribuição. **rate**: parâmetro da distribuição. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **n**: número de observações.

Qui-quadrado	dchisq(x, df, ncp=0, opções) pchisq(q, df, ncp=0, opções) qchisq(p, df, ncp=0, opções) rchisq(n, df, ncp=0)	**x**: vetor contendo os quantis. **df**: graus de liberdade. **ncp**: parâmetro de não centralidade. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **n**: número de observações.

t-Student	dt(x, df, ncp=0, opções) pt(q, df, ncp=0, opções) qt(p, df, opções) rt(n, df)	**x**: vetor contendo os quantis. **df**: graus de liberdade. **ncp**: parâmetro de não centralidade. **q**: vetor contendo os quantis. **p**: vetor contendo as probabilidades. **n**: número de observações.

F-Snedecor	df(x, df1, df2, opções) pf(q, df1, df2, ncp=0, opções) qf(p, df1, df2, opções) rf(n, df1, df2)	**x**: vetor contendo os quantis. **df1**: graus de liberdade do numerador. **df2**: graus de liberdade do denominador. **q**: vetor contendo os quantis. **ncp**: parâmetro de não centralidade. **p**: vetor contendo as probabilidades. **n**: número de observações.

O termo opções que aparece em algumas funções pode ser substituído por:

lower.tail = (TRUE)
TRUE: Calcula as probabilidades da forma P(X <= x).
FALSE: Calcula as probabilidades da forma P(X > x).

log = (FALSE)
log.p = (FALSE)
TRUE: As probabilidades p são dadas como o logarítmo natural de p (log(p)).

Em caso de dúvida, digite ***?nome_da_função*** para obter a ajuda necessária.

Para mais distribuições, utilize o comando: **help.search("distribution")** e em seguida utilize: ***?Nome_da_distribuição*** para mais informações sobre a distribuição escolhida.

Exemplos

Dividindo as observações em intervalos

```
salario <- c(12, .4, 5, 2, 50, 8, 3, 1, 4, .25)
intervalo <- cut(salario,breaks=c(0,1,5,max(salario)))
intervalo
[1] (5,50] (0,1]  (1,5]  (1,5]  (5,50] (5,50] (1,5]  (0,1]  (1,5]  (0,1]
Levels: (0,1] (1,5] (5,50]
```

Freqüência de observações em cada intervalo

```
table(intervalo)
intervalo
 (0,1]  (1,5] (5,50]
     3      4      3
intervalo
[1] (5,50] (0,1]  (1,5]  (1,5]  (5,50] (5,50] (1,5]  (0,1]  (1,5]  (0,1]
Levels: (0,1] (1,5] (5,50]
```

Rotulando os intervalos

```
levels(intervalo) <-c("pobre","rico"," rolando na grana")
table(intervalo)
intervalo
            pobre              rico  rolando na grana
                3                 4                 3
```

Criando variáveis e exibindo-as em tabelas

```
Peso= c(60, 75, 55, 68)
Altura = c(65, 61, 70, 65)
Genero = c("Fe","Fe","M","Fe")
estudo = data.frame(Peso,Altura,Genero)
estudo
  Peso Altura Genero
1   60     65     Fe
2   75     61     Fe
3   55     70      M
4   68     65     Fe
```

Alterando os rótulos das variáveis

```
estudo = data.frame(P=Peso,H=Altura,G=Genero)
row.names(estudo)<-c("Maria","Alice","André","Julia")
estudo
       P  H  G
Maria 60 65 Fe
Alice 75 61 Fe
André 55 70  M
Julia 68 65 Fe
```

Histogramas com curvas teóricas

```
x=runif(100)

hist(x,probability=TRUE,main="Uniforme
[0,1]",
ylab="Densidade",col="yellow")

curve(dunif(x,0,1),add=T)
```

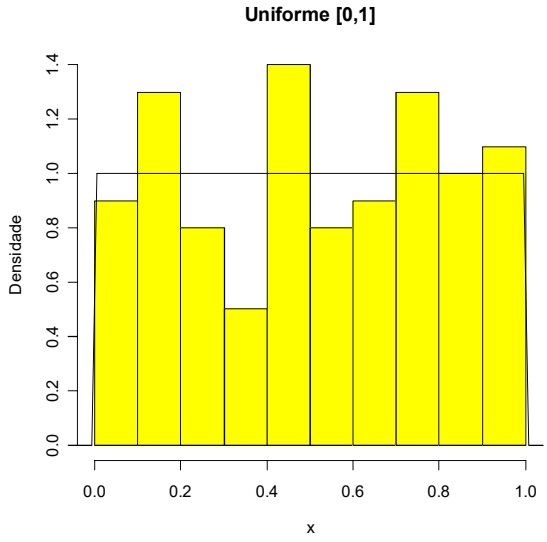


```
n=10;p=0.25
x=rbinom(100,n,p)

hist(x,probability=TRUE,ylab="Densidade",
col="pink", main="Binomial",ylim=c(0,0.30))

xvalores=0:n

points(xvalores,dbinom(xvalores,n,p),type="h",
lwd=3)

points(xvalores,dbinom(xvalores,n,p),type="p",
lwd=3)
```

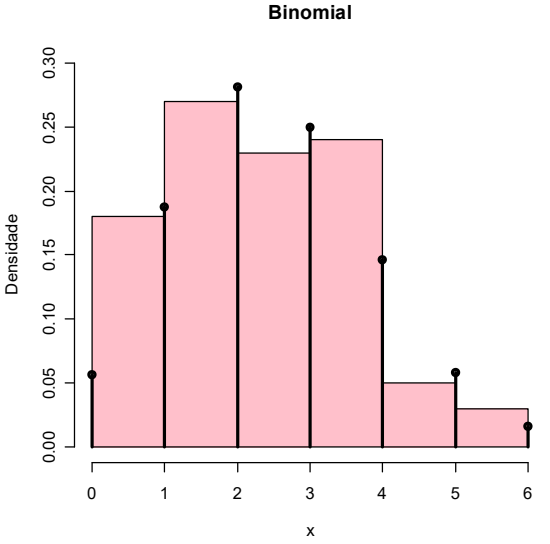


```
x=rnorm(100)

hist(x,probability=TRUE,col="lightbl
ue",
main="Normal(0,1)",ylab="Densidade",
ylim=c(0,0.5),xlim=c(-3,3))

curve(dnorm(x),add=T)
```

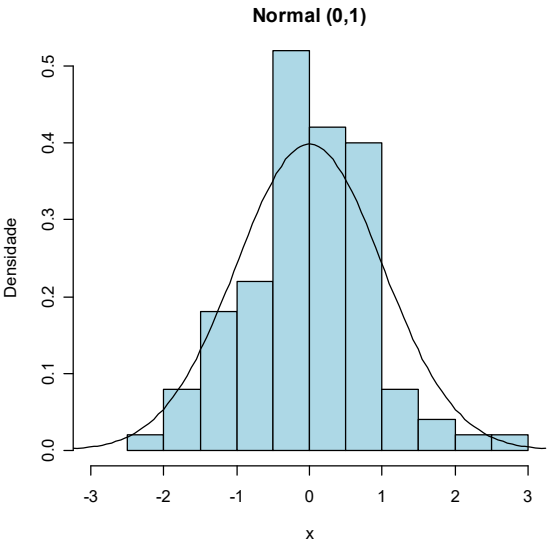

```
x=rexp(100,1/2500)
hist(x,probability=TRUE,
col="lightgreen",main="Exponencial
com média=2500",ylab="Densidade")

curve(dexp(x,1/2500),add=T)
```

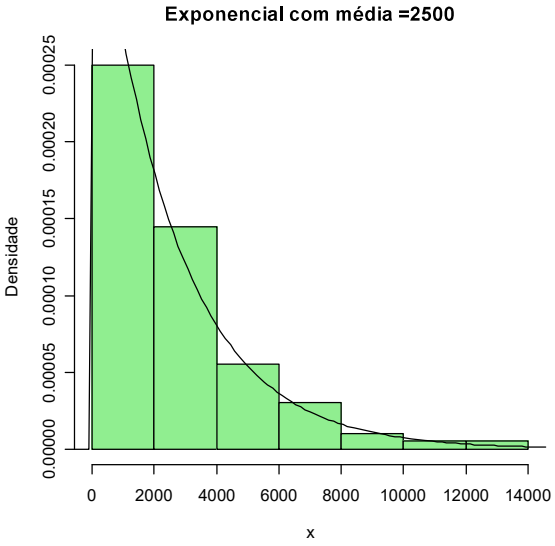

Bibliografia

Bussab, W. de O. e Morettin, P. A. (2003). **Estatística Básica, 5ª ed**. São Paulo: Editora Saraiva.

The R Project for Statistical Computing (08/2006). **www.r-project.org**